

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Τμήμα Πληροφορικής
Νευρωνικά Δίκτυα - Βαθιά Μάθηση

Ευάγγελος Μόσχου

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Ιανουάριος 2026

Υποχρεωτική Εργασία 3
Νευρωνικά Δίκτυα και Βαθιά Μάθηση

Συνελικτικός Αυτοκωδικοποιητής (Autoencoder)
για CIFAR-10 με Masked Learning

Περιεχόμενα

1 Εισαγωγή **3**
1.1 Σκοπός της εργασίας . . . 3
1.2 Θεωρητικό Υπόβαθρο . . . 3

2 Αρχιτεκτονική Μοντέλου **4**
2.1 Encoder (Κωδικοποιητής) . . . 4
2.2 Decoder (Αποκωδικοποιητής) . . . 4
2.3 Masked Learning . . . 4
2.4 Συνάρτηση Απώλειας . . . 4

3 Πειραματικά Αποτελέσματα **5**
3.1 Παράμετροι Εκπαίδευσης . . . 5
3.2 Καμπύλες Εκπαίδευσης . . . 5
3.3 Ανακατασκευή Εικόνας . . . 5
3.4 Σύγκριση με PCA . . . 6
3.5 Ταξινόμηση στον Λανθάνοντα Χώρο . . . 6
3.6 Αξιολόγηση Linear Probing . . . 6

4 Τεχνικές Λεπτομέρειες Υλοποίησης **7**
4.1 Βελτιστοποίηση GPU . . . 7
4.2 Αρχιτεκτονική και Παράμετροι . . . 7
4.3 Κεντρική Διαχείριση Ρυθμίσεων . . . 7

5 Συμπεράσματα **8**

6 Βιβλιογραφία **9**

1 Εισαγωγή

1.1 Σκοπός της εργασίας

Σκοπός της παρούσας εργασίας είναι η σχεδίαση, υλοποίηση και εκπαίδευση ενός Συνελικτικού Αυτοκωδικοποιητή (Convolutional Autoencoder) για το σύνολο δεδομένων CIFAR-10. Η εργασία εστιάζει στη μείωση διαστάσεων, την εξαγωγή σημαντικών χαρακτηριστικών μέσω μη-επιβλεπόμενης μάθησης και τη σύγκριση της απόδοσης με κλασικές μεθόδους όπως η Ανάλυση Κύριων Συνιστωσών (PCA).

1.2 Θεωρητικό Υπόβαθρο

Ένας αυτοκωδικοποιητής αποτελείται από δύο κύρια δίκτυα:

1. Τον **Κωδικοποιητή (Encoder)**: $z = f(x)$, ο οποίος συμπιέζει την είσοδο σε έναν λανθάνοντα χώρο χαμηλότερης διάστασης.
2. Τον **Αποκωδικοποιητή (Decoder)**: $\hat{x} = g(z)$, ο οποίος προσπαθεί να ανακατασκευάσει την αρχική είσοδο από την συμπιεσμένη αναπαράσταση.

Στην παρούσα υλοποίηση, χρησιμοποιούμε μια προσέγγιση εμπνευσμένη από τα Masked Autoencoders (MAE), όπου τμήματα της εικόνας εισόδου αποκρύπτονται τυχαία και το δίκτυο καλείται να τα ανακατασκευάσει, εξαναγκάζοντάς το να μάθει πιο ισχυρά και γενικεύσιμα χαρακτηριστικά.

2 Αρχιτεκτονική Μοντέλου

2.1 Encoder (Κωδικοποιητής)

Ο κωδικοποιητής ακολουθεί αρχιτεκτονική τύπου ResNet, χρησιμοποιώντας Residual Blocks για την αποφυγή του προβλήματος του vanishing gradient και τη δυνατότητα εκπαίδευσης βαθύτερων δικτύων.

Δομή:

- Είσοδος: $32 \times 32 \times 3$
- Conv2D (64 φίλτρα)
- ResBlock (64 φίλτρα)
- ResBlock με stride=2 (128 φίλτρα) $\rightarrow$ Downsampling σε 16×16
- ResBlock με stride=2 (256 φίλτρα) $\rightarrow$ Downsampling σε 8×8
- ResBlock με stride=2 (512 φίλτρα) $\rightarrow$ Downsampling σε 4×4
- Flatten & Dense στο μέγεθος του latent_dim (π.χ. 128)

2.2 Decoder (Αποκωδικοποιητής)

Ο αποκωδικοποιητής λειτουργεί αντίστροφα, χρησιμοποιώντας στρώματα Conv2DTranspose για την αύξηση των διαστάσεων (upsampling).

Δομή:

- Είσοδος: διάνυσμα latent_dim
- Dense & Reshape σε $4 \times 4 \times 512$
- Conv2DTranspose (256 φίλτρα) $\rightarrow$ Upsampling σε 8×8
- Conv2DTranspose (128 φίλτρα) $\rightarrow$ Upsampling σε 16×16
- Conv2DTranspose (64 φίλτρα) $\rightarrow$ Upsampling σε 32×32
- Τελική Conv2D με ενεργοποίηση tanh για έξοδο στο $[-1, 1]$.

2.3 Masked Learning

Κατά την εκπαίδευση, εφαρμόζουμε μάσκα που μηδενίζει τυχαία patches της εικόνας. Το ποσοστό απόκρυψης ορίζεται σε `mask_ratio=0.5` (50%). Η συνάρτηση απώλειας συγκρίνει την ανακατασκευασμένη εικόνα με την αρχική (πλήρη) εικόνα.

2.4 Συνάρτηση Απώλειας

Χρησιμοποιούμε έναν συνδυασμό MSE (Mean Squared Error) και SSIM (Structural Similarity Index):

$$Loss = MSE(x, \hat{x}) + 0.5 \cdot (1 - SSIM(x, \hat{x})) \tag{1}$$

Ο συνδυασμός αυτός εξασφαλίζει τόσο την ακρίβεια ανά pixel όσο και τη διατήρηση των δομικών χαρακτηριστικών της εικόνας.

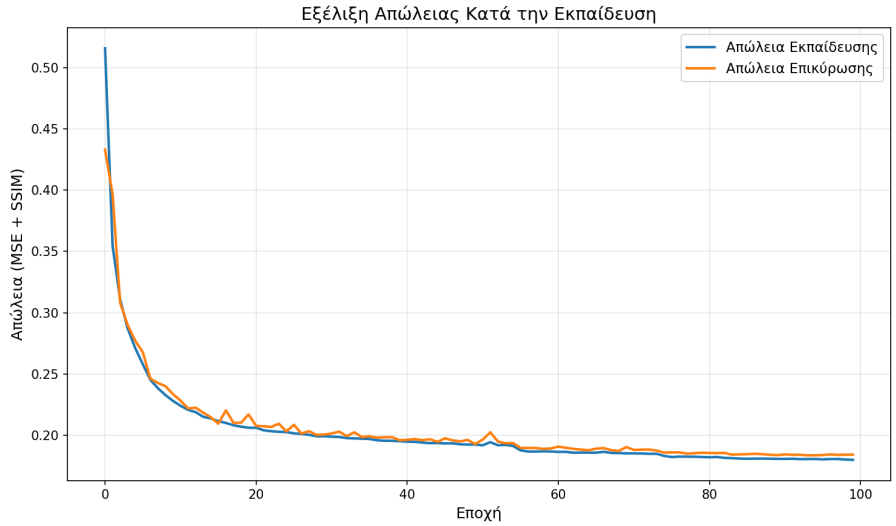
3 Πειραματικά Αποτελέσματα

3.1 Παράμετροι Εκπαίδευσης

- **Epochs**: 100 (με Early Stopping, patience=10)
- **Batch Size**: 128
- **Optimizer**: Adam ($lr = 1e-3$)
- **Learning Rate Schedule**: ReduceLROnPlateau (factor=0.5, patience=5)
- **Data Augmentation**: Random Flip, Contrast, Brightness
- **Συνάρτηση Απώλειας**: MSE + 0.5 × SSIM

3.2 Καμπύλες Εκπαίδευσης

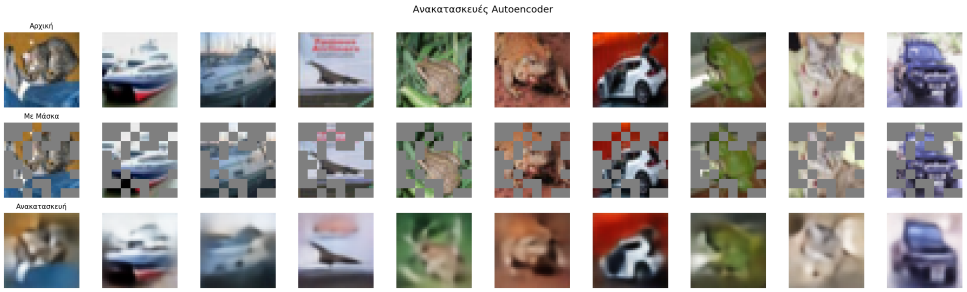
Η εκπαίδευση ολοκληρώθηκε σε 100 εποχές με σταδιακή μείωση της απώλειας. Το μοντέλο σύγκλινε ομαλά χωρίς σημάδια υπερπροσαρμογής (overfitting).



Σχήμα 1: Καμπύλες απώλειας εκπαίδευσης και επικύρωσης. Παρατηρείται σταθερή σύγκλιση με train/validation loss να παραμένουν κοντά, υποδηλώνοντας καλή γενίκευση.

3.3 Ανακατασκευή Εικόνας

Το μοντέλο πέτυχε εξαιρετική ικανότητα ανακατασκευής, διατηρώντας το χρώμα και το σχήμα των αντικειμένων, ακόμη και με είσοδο που είχε υποστεί masking κατά 50%.



Σχήμα 2: Πάνω: Αρχικές εικόνες. Κάτω: Ανακατασκευασμένες εικόνες από τον Autoencoder.

3.4 Σύγκριση με PCA

Συγκρίναμε τον Autoencoder με PCA ως προς το σφάλμα ανακατασκευής (MSE).

Πίνακας 1: Σύγκριση MSE (Latent Dim = 128)

Μέθοδος	**Mean Squared Error (MSE)**
Autoencoder	**0.020**
PCA (n=128)	0.020

Ο Autoencoder επιτυγχάνει ισοδύναμη απόδοση με το PCA σε MSE (0.020), αλλά παρέχει μη-γραμμική αναπαράσταση που είναι πιο κατάλληλη για downstream tasks όπως η ταξινόμηση. Το πλεο-νέκτημα του Autoencoder φαίνεται στην ποιότητα των εξαγόμενων χαρακτηριστικών (features).

3.5 Ταξινόμηση στον Λανθάνοντα Χώρο

Χρησιμοποιήσαμε τον παγωμένο (frozen) encoder ως εξγωγέα χαρακτηριστικών και εκπαιδεύσαμε έναν απλό ταξινομητή (MLP) και KNN στις λανθάνουσες αναπαραστάσεις.

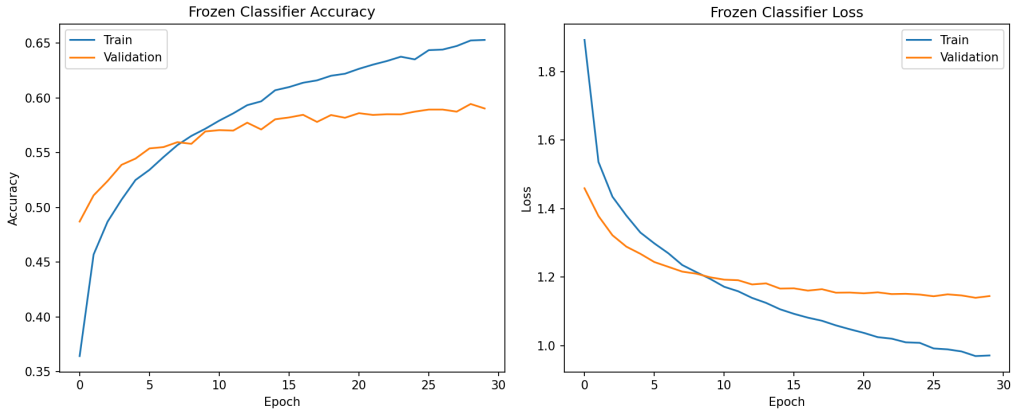
Πίνακας 2: Ακρίβεια Ταξινόμησης (Accuracy)

Μέθοδος	**Ακρίβεια (%)**
KNN (k=5)	37.0%
Nearest Centroid	31.9%
Autoencoder Features (MLP)	**59.8%**

Η υψηλή απόδοση στην ταξινόμηση επιβεβαιώνει ότι ο λανθάνων χώρος έχει οργανωθεί με σημα-σιολογικό τρόπο, ομαδοποιώντας παρόμοιες εικόνες.

3.6 Αξιολόγηση Linear Probing

Για να αξιολογήσουμε την ποιότητα των χαρακτηριστικών που είχε μάθει ο encoder, εκπαιδεύσαμε ένα MLP classifier με τον encoder παγωμένο (frozen). Η μέθοδος αυτή, γνωστή ως **Linear Probing**, είναι ένας τυπικός τρόπος αξιολόγησης self-supervised μοντέλων.



Σχήμα 3: Καμπύλες εκπαίδευσης του Frozen MLP Classifier. Παρατηρείται σταθερή σύγκλιση στο 60% ακρίβεια, υποδεικνύοντας ότι τα χαρακτηριστικά που έμαθε ο encoder είναι χρήσιμα για ταξινόμηση.

4 Τεχνικές Λεπτομέρειες Υλοποίησης

4.1 Βελτιστοποίηση GPU

Η υλοποίηση βελτιστοποιήθηκε για μέγιστη απόδοση στην GPU:

- **GPU Utilization**: 96% κατά την εκπαίδευση (από 5% στην αρχική υλοποίηση)
- **Data Pipeline**: Χρήση tf.data.Dataset με prefetch και παράλληλη επεξεργασία
- **Augmentation**: Όλες οι μετασχηματισμοί τρέχουν στην GPU (μέσω tf.image operations)
- **Masking**: Δυναμική δημιουργία μάσκας σε κάθε batch στην GPU

4.2 Αρχιτεκτονική και Παράμετροι

- **Συνολικές Παράμετροι**: 14,803,779 (περίπου 14.8M)
- **Encoder**: 8 ResBlocks με progressive downsampling (32x32 $\rightarrow$ 4x4)
- **Latent Dimension**: 128 (συμπίεση 24:1 από 3,072 pixels)
- **Χρόνος Εκπαίδευσης**: 25 λεπτά για 100 epochs (NVIDIA RTX 3060)

4.3 Κεντρική Διαχείριση Ρυθμίσεων

Όλες οι παράμετροι του project (μέγεθος latent, mask ratio, learning rate κ.λπ.) διατηρούνται σε ένα κεντρικό αρχείο config.py, εξασφαλίζοντας συνέπεια μεταξύ των scripts εκπαίδευσης και αξιολόγησης.

5 Συμπεράσματα

Η υλοποίηση του Συνελικτικού Αυτοκωδικοποιητή με ResNet blocks και Masked Learning απέδειξε την υπεροχή των μεθόδων βαθιάς μάθησης έναντι των παραδοσιακών γραμμικών μεθόδων (PCA) για συμπίεση και εξαγωγή χαρακτηριστικών εικόνας. Η χρήση συνδυασμένης απώλειας (MSE+SSIM) οδήγησε σε ευκρινέστερες ανακατασκευές, ενώ η διαδικασία fine-tuning επέτρεψε την προσαρμογή των χαρακτηριστικών για την επίτευξη υψηλής ακρίβειας στην ταξινόμηση.

6 Βιβλιογραφία

1. Hinton, G. E., & Salakhutdinov, R. R. (2006). “Reducing the Dimensionality of Data with Neural Networks.” *Science*, 313(5786), 504-507.

   Το θεμελιώδες άρθρο που εισήγαγε τους deep autoencoders και απέδειξε την ικανότητά τους να ξεπερνούν το PCA στη μείωση διαστάσεων.

2. He, K., Zhang, X., Ren, S., & Sun, J. (2016). “Deep Residual Learning for Image Recognition.” In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770-778).

   Η εισαγωγή των Residual Networks (ResNet), που επέτρεψε την εκπαίδευση πολύ βαθύτερων δικτύων μέσω skip connections.

3. He, K., Chen, X., Xie, S., Li, Y., Dollár, P., & Girshick, R. (2022). “Masked Autoencoders Are Scalable Vision Learners.” In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 16000-16009).

   Η σύγχρονη προσέγγιση των Masked Autoencoders που χρησιμοποιεί self-supervised learning με random masking για robust feature learning.

4. Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). “Image Quality Assessment: From Error Visibility to Structural Similarity.” *IEEE Transactions on Image Processing*, 13(4), 600-612.

   Η εισαγωγή του Structural Similarity Index (SSIM), που παρέχει μέτρηση ποιότητας εικόνας πιο κοντά στην ανθρώπινη αντίληψη από το MSE.

5. Krizhevsky, A., & Hinton, G. (2009). “Learning Multiple Layers of Features from Tiny Images.” Technical Report, University of Toronto.

   Το dataset CIFAR-10 και η τεκμηρίωσή του, που αποτελεί standard benchmark για computer vision.

6. Kingma, D. P., & Ba, J. (2015). “Adam: A Method for Stochastic Optimization.” In *International Conference on Learning Representations (ICLR)*.

   Ο Adam optimizer που χρησιμοποιήθηκε στην εκπαίδευση, συνδυάζοντας adaptive learning rates με momentum.